

# EM算法

---

✓ Expectation-Maximization :


✎ 最大似然


✎ EM算法推导

✎ GMM ( 高斯混合模型 )

# EM算法

## ✓ 最大似然估计

 一个栗子：假如你去赌场，但是不知道能不能赚钱，你就在门口堵着出来一个人就问一个赚了还是赔了，如果问了5个人都说赚了，那么你就会认为，赚钱的概率肯定是非常大的。

 已知：（1）样本服从分布的模型，（2）观测到的样本  
求解：模型的参数

总的来说：极大似然估计就是用来估计模型参数的统计学方法

# EM算法

✓ 最大似然数学问题（100名学生的身高问题）

✎ 样本集  $X = \{x_1, x_2, \dots, x_N\}$   $N = 100$

✎ 概率密度： $p(x_i|\theta)$  抽到男生  $i$ （的身高）的概率

✎  $\theta$  是服从分布的参数

✎ 独立同分布：同时抽到这100个男生的概率就是他们各自概率的乘积

# EM算法

✓ 最大似然数学问题（100名学生的身高问题）

✎ 最大似然函数：
$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta)$$
（对数是为了乘法转加法）

✎ 什么样的参数  $\theta$  能够使得出现当前这批样本的概率最大

✎ 已知某个随机样本满足某种概率分布，但是其中具体的参数不清楚，参数估计就是通过若干次试验，观察其结果，利用结果推出参数的大概值。

# EM算法

✓ 问题又难了一步

✎ 现在这100个人中，不光有男生，还有女生（2个类别，2种参数）

✎ 男生和女生的身高都服从高斯分布，但是参数不同（均值，方差）

✎ 用数学的语言描述：抽取得到的每个样本都不知道是从哪个分布抽取的

✎ 求解目标：男生和女生对应的身高的高斯分布的参数是多少

# EM算法

✓ 加入隐变量


✎ 用 $Z=0$ 或 $Z=1$ 标记样本来自哪个分布，则 $Z$ 就是隐变量。

✎ 最大似然函数：
$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta) = \sum_{i=1}^m \log \sum_{z_i} p(x_i, z_i; \theta)$$

✎ 求解：在给定初始值情况下进行迭代求解

$$p(x_i; \theta) = \sum_z p(x_i, z; \theta)$$

# EM算法



两个硬币的初始假设的分布

A: 0.6几率正面

B: 0.5几率正面

投掷出5正5反的概率:

$$pA = C(10, 5) * (0.6^5) * (0.4^5)$$

$$pB = C(10, 5) * (0.5^5) * (0.5^5)$$

选择硬币A的概率:

$$pA / (pA + pB) = 0.45$$

选择硬币B的概率

$$1 - pA = 0.55$$

# EM算法

## ✓ EM算法推导

✎ 问题：样本集 $\{x(1), \dots, x(m)\}$ ，包含 $m$ 个独立的样本。  
其中每个样本 $i$ 对应的类别 $z(i)$ 是未知的，所以很难用最大似然求解。

$$l(\theta) = \sum_{i=1}^m \log p(x_i; \theta) = \sum_{i=1}^m \log \sum_z p(x_i, z_i; \theta)$$

✎ 上式中，要考虑每个样本在各个分布中的情况。  
本来正常求偏导就可以了，但是现在 $\log$ 后面还有求和，这就难解了！



# EM算法

## ✓ EM算法推导

✎ 右式分子分母同时乘  $Q(z)$  :  $\log \sum_{z_i} p(x_i, z_i; \theta) = \log \sum_{z_i} Q(z_i) \frac{p(x_i, z_i; \theta)}{Q(z)}$


✎ 为嘛这么干呢？说白了就是要凑-Jensen不等式（ $Q(z)$ 是 $Z$ 的分布函数）

# EM算法

## ✓ Jensen不等式

✎ 设 $f$ 是定义域为实数的函数，如果对于所有的实数 $x$ 。  
如果对于所有的实数 $x$ ， $f(x)$ 的二次导数大于等于0，那么 $f$ 是凸函数。

✎ 如果 $f$ 是凸函数， $X$ 是随机变量，那么： $E[f(X)] \geq f(E[X])$



实线 $f$ 是凸函数， $X$ 有0.5的概率是 $a$ ，有0.5的概率是 $b$   
 $X$ 的期望值就是 $a$ 和 $b$ 的中值了

# EM算法

✓ Jensen不等式

$$f(E[X]) \geq E[f(X)]$$

Jensen不等式应用于凹函数时，不等号方向反向

由于  $\sum_{z_i} Q(z_i) \frac{p(x_i, z_i; \theta)}{Q(z)}$  是  $\frac{p(x_i, z_i; \theta)}{Q(z)}$  的期望

$p(x_i, z_i; \theta)$  为 r.v. 因为  $z$  还未取值

假设  $Y = \frac{p(x_i, z_i; \theta)}{Q(z)}$  则:  $\log \sum_{z_i} Q \frac{p(x_i, z_i; \theta)}{Q} = \log \sum_Y P(Y) Y = \log E(Y)$

$$\leq \sum_z Q(z) \log \frac{p(x_i, z; \theta)}{Q(z)}$$

# EM算法

✓ Jensen不等式

✎ 可得： $\log E(Y) \geq E(\log Y) = \sum_Y P(Y) \log Y = \sum_{z_i} Q(z_i) \log \frac{p(x_i, z_i; \theta)}{Q(z_i)}$


✎ 结论： $l(\theta) = \sum_{i=1}^m \log \sum_{z_i} p(x_i, z_i; \theta) \geq \sum_{i=1}^m \sum_{z_i} Q(z_i) \log \frac{p(x_i, z_i; \theta)}{Q(z_i)}$

✎ 下界比较好求，所以我们要优化这个下界来使得似然函数最大

# EM算法

✓ 优化下界

✎ 迭代到收敛



# EM算法


✓ Jensen不等式

✎ 如何能使得等式成立呢？（取等号）

✎ Jensen中等式成立的条件是随机变量是常数： $Y = \frac{p(x_i, z_i; \theta)}{Q(z)} = c$

✎  $Q(z_i)$  是 $z$ 的分布函数： $\sum_{z_i} Q(z_i) = \sum_{z_i} \frac{p(x_i, z_i; \theta)}{c} = 1$

✎ 所有的分子和等于常数 $C$ （分母相同）



当A.B  
两点在  
一起时  
等号成立  
所以才会吐  
一个 constant

# EM算法

✓ Q(z)求解

✎ 
$$\sum_{z_i} Q(z_i) = \sum_{z_i} \frac{p(x_i, z_i; \theta)}{c} = 1$$

✎ 由上式可得C就是 $p(x_i, z_i)$ 对z求和

✎ 
$$Q(z) = \frac{p(x_i, z_i; \theta)}{c} = \frac{p(x_i, z_i; \theta)}{\sum_{z_i} p(x_i, z_i; \theta)} = \frac{p(x_i, z_i; \theta)}{p(x_i)} = p(z|x_i; \theta)$$

✎ Q(z)代表第i个数据是来自 $z_i$ 的概率

# EM算法

## ✓ EM算法流程

✎ 初始化分布参数 $\theta$

✎ E-step : 根据参数 $\theta$ 计算每个样本属于 $z_i$ 的概率(也就是我们的Q)

✎ M-Step : 根据Q, 求出含有 $\theta$ 的似然函数的下界并最大化它, 得到新的参数 $\theta$

✎ 不断的迭代更新下去



# EM算法

---

✓ GMM ( 高斯混合模型 )

✎ 数据可以看作是从数个 Gaussian Distribution 中生成出来的

✎ GMM 由  $K$  个 Gaussian 分布组成, 每个 Gaussian 称为一个 “Component”

✎ 类似k-means方法, 求解方式跟EM一样

✎ 不断的迭代更新下去